

Relatório do Projeto: Aprendizagem de Máquina

Agrupamento KCM-K-GH e Classificação Bayesiana (Dataset Ionosphere)

6 de junho de 2026

Resumo

Este relatório detalha as metodologias e implementações desenvolvidas para o projeto da disciplina de Aprendizagem de Máquina, seguindo rigorosamente as definições propostas na literatura base e nas orientações do professor. A primeira etapa consistiu no agrupamento das amostras do conjunto de dados *Ionosphere* utilizando o algoritmo *Gaussian kernel c-means hard clustering* (KCM-K-GH) com inicialização aleatória e padronização Z-score, determinando o número ótimo de clusters ($c^* = 2$) via Índice de Silhueta. A segunda etapa focou na avaliação rigorosa de cinco classificadores (Bayes Gaussiano com Máxima Verossimilhança pura, kNN Bayesiano probabilístico, Parzen, Regressão Logística e Voto Majoritário) por meio de validação cruzada aninhada repetida (30×10 -folds) nos cenários originais e derivados do agrupamento. Ao final, é apresentada uma seção adicional propondo melhorias arquiteturais originais sobre os métodos clássicos, como tratamento de resiliência e regularização *Ledoit-Wolf*.

Sumário

1	Questão 1: Agrupamento KCM-K-GH	2
1.1	Metodologia e Implementação	2
1.2	Escolha do Número Ótimo de Clusters (c^*)	2
1.3	Análise da Matriz de Confusão e ARI	3
1.4	Visualização dos Clusters via PCA	4
2	Questão 2: Comparação de Classificadores	5
2.1	Modelos e Regras de Decisão	5
2.2	Metodologia Experimental e Busca de Hiperparâmetros	5
2.3	Curvas de Aprendizagem	5
2.4	Tabelas de Resultados e Diagramas CD	7
3	Sugerindo Novas Melhorias (Abordagens Customizadas)	8
3.1	Resiliência contra Clusters Vazios no KCM-K-GH	8
3.2	Regularização de Covariância de Ledoit-Wolf	10

1 Questão 1: Agrupamento KCM-K-GH

1.1 Metodologia e Implementação

O conjunto de dados *Ionosphere* [Sigillito et al., 1989] foi rigorosamente pré-processado (padronização via *Z-score*) de acordo com as instruções antes de ser alimentado ao algoritmo de agrupamento rígido baseado em kernel gaussiano com pesos globais (KCM-K-GH) [de Carvalho et al., 2018]. A inicialização dos protótipos foi feita de forma puramente aleatória (Forgy), sem indução externa de densidade. O algoritmo procura a partição ótima e os parâmetros do kernel minimizando a seguinte função objetivo:

$$J = 2 \sum_{i=1}^c \sum_{k=1}^n u_{ik} (1 - K(x_k, g_i)) \quad (1)$$

onde $u_{ik} \in \{0, 1\}$ indica o grau de pertinência rígida da amostra x_k ao cluster i (com a restrição $\sum_{i=1}^c u_{ik} = 1$), c é o número de clusters, n o número de amostras, e $K(x_k, g_i)$ é a função de kernel Gaussiano multivariada com parâmetros de largura globais s_j^2 (um para cada variável):

$$K(x_k, g_i) = \exp \left(-\frac{1}{2} \sum_{j=1}^p \frac{(x_{kj} - g_{ij})^2}{s_j^2} \right) \quad (2)$$

sendo p a dimensão dos dados (número de *features*) e g_i o protótipo do cluster i .

O código foi implementado com extrema fidelidade às equações de atualização algébricas descritas pela literatura base. A cada iteração, os parâmetros são atualizados de forma minimizadora em três etapas sequenciais (Atribuição, Atualização dos Protótipos e Ajuste dos Pesos).

1.2 Escolha do Número Ótimo de Clusters (c^*)

Para determinar a partição ótima e o número de clusters c^* , o algoritmo foi executado para valores de $c \in \{2, 3, 4, 5, 6\}$. Devido à natureza estocástica da inicialização de Forgy, cada c foi testado com 100 execuções independentes, capturando a partição que minimizou a função objetivo J para aquele c .

A definição de c^* baseou-se na maximização do **Índice de Silhueta**. Como a inicialização é aleatória, a estrutura do conjunto de dados se mostrou altamente instável para partições muito granulares, forçando o algoritmo a escolher a partição mais macroscópica. Conforme exibido na Figura 1, o maior valor de Silhueta ocorreu inequivocamente para $c^* = 2$.




Figura 1: Gráfico do Índice de Silhueta versus o número de clusters c . O pico máximo determinou a escolha de $c^* = 2$.

1.3 Análise da Matriz de Confusão e ARI

Utilizando $c^* = 2$, comparamos a partição obtida com as classes *a priori* da base (Good vs. Bad). A Figura 2 ilustra a Matriz de Confusão para esta abordagem.




Figura 2: Matriz de confusão cruzando as classes a priori com os clusters encontrados.

Observa-se que a separação é coerente, embora misture parte das observações. O Cluster 1 (Rótulo 0) concentra sua maior força nas amostras "Good", enquanto o Cluster 2 apresenta um balanço extremo entre ambas as classes. O **Índice de Rand Ajustado (ARI)** medido contra as classes a priori reais atingiu o valor de **0.24**.

1.4 Visualização dos Clusters via PCA

Para corroborar a matriz de confusão e demonstrar o arranjo geométrico dos grupos encontrados, aplicou-se a Análise de Componentes Principais (PCA) em duas dimensões. A Figura 3 ilustra a projeção bidimensional das amostras.




Figura 3: Projeção PCA 2D coloridas pelos clusters formados pelo algoritmo KCM-K-GH ($c^* = 2$).

A divisão visual faz bastante sentido espacialmente, cortando a nuvem de dados ao meio na sua dimensão de maior variação, o que justifica a escolha do algoritmo sob o ponto de vista da densidade global, evitando forçar grupos artificiais.

2 Questão 2: Comparação de Classificadores

2.1 Modelos e Regras de Decisão

A implementação exigiu alto rigor estatístico e obediência ao critério bayesiano e à estimação de máxima verossimilhança.

- **Classificador Bayesiano Gaussiano:** Modelou a densidade condicional assumindo uma matriz de covariância densa por classe, utilizando puramente a **Estimativa de Máxima Verossimilhança (MLE)**, conforme exigido pela literatura clássica.
- **Classificador Bayesiano k -NN:** Diferente do k -NN discriminativo comum (de prateleira), desenvolvemos um algoritmo matemático puro que computou o volume da hipersfera contendo os k vizinhos da mesma classe e aplicou sobre a Fórmula de Bayes de forma a obter a densidade de probabilidade legítima $\hat{p}(x|\omega_i)$.
- **Classificador de Parzen:** Modelagem não paramétrica com Função de Kernel Gaussiano simétrica contínua (KDE).
- **Regressão Logística e Comitê Majority Voting:** A Regressão Logística foi aplicada conforme sua premissa discriminativa padrão. Para agregar as previsões dos quatro modelos base em um único *Ensemble*, empregamos a regra do Voto Majoritário (*Majority Voting*). Conforme teorizado matematicamente por Kittler et al. [Kittler et al., 1998], o Voto Majoritário consolida-se sob a ótica Bayesiana como uma simplificação robusta e pragmática da Regra da Soma. Sob a suposição de erros independentes e invariância de fronteiras, este mecanismo minimiza a variância dos erros preditivos e favorece uma generalização superior sem adicionar complexidade computacional.

2.2 Metodologia Experimental e Busca de Hiperparâmetros

O ambiente avaliativo baseou-se em Validação Cruzada Aninhada (Nested CV) rigorosa ($10 \text{ Folds} \times 30 \text{ Repetições} = 300$ amostras estatísticas). No laço interno, utilizou-se *GridSearch* com 5-folds para otimização dos métodos não-paramétricos. Os experimentos foram aplicados sobre dois cenários de aprendizado: **Cenário A** (Classes a priori binárias) e **Cenário B** (Rótulos do Agrupamento $c^* = 2$). Todas as análises seguiram o Teste Não-paramétrico de **Friedman** ($\alpha = 0.05$) com pós-teste de **Nemenyi**.

2.3 Curvas de Aprendizagem

As Curvas de Aprendizagem foram concebidas variando o percentual de treino de 5% até 95%.




Figura 4: Curva de Aprendizagem — Cenário A (Rótulos Originais).

No Cenário A, a formulação probabilística rigorosa do k-NN provou seu valor, mantendo alta estabilidade. O Voto Majoritário dominou o cenário.




Figura 5: Curva de Aprendizagem — Cenário B (Rótulos do Agrupamento KCM-K-GH $c^* = 2$).

No Cenário B, os modelos não-paramétricos saltam rapidamente para pontuações próximas de 1.0 (já que é uma tarefa trivial espacial). Entretanto, nota-se a forte instabilidade e queda do **Bayes Gaussiano (MLE)** no início da curva. Como o agrupamento gera partições desbalanceadas e não há regularização de covariância no modelo clássico, ele sofre colapso por singularidade (matrizes não invertíveis) em sub-amostragens.

2.4 Tabelas de Resultados e Diagramas CD

Tabela 1: Estimativas Pontuais e IC (95%) do F-measure (macro) comparando os Cenários A e B.

Classificador	Cenário A (Rótulos a Priori)		Cenário B (Clusters)	
	Média	IC (95%)	Média	IC (95%)
Bayes Gaussiano	0.883	[0.876, 0.889]	0.995	[0.993, 0.997]
<i>k</i> -NN Bayesiano	0.893	[0.887, 0.899]	0.974	[0.969, 0.979]
Parzen	0.848	[0.840, 0.855]	0.830	[0.816, 0.845]
Regressão Log.	0.859	[0.852, 0.866]	1.000	[1.000, 1.000]
Voto Majoritário	0.928	[0.923, 0.933]	0.973	[0.968, 0.978]




Figura 6: Diagrama de Diferença Crítica (CD) para o Cenário A.




Figura 7: Diagrama de Diferença Crítica (CD) para o Cenário B.

3 Sugerindo Novas Melhorias (Abordagens Customizadas)

Ao observarmos as limitações matemáticas intrínsecas à implementação dos algoritmos clássicos exigidos, nossa equipe desenvolveu e validou duas melhorias arquiteturais cruciais, as quais demonstram superar substancialmente os problemas encontrados nas seções anteriores.

3.1 Resiliência contra Clusters Vazios no KCM-K-GH

Na formulação pura do agrupamento por kernel, inicializações aleatórias (Forgy) em espaços esparsos frequentemente induzem o colapso de protótipos que deixam de atrair amostras. Para evitar que o algoritmo reduza a granularidade da partição (como observado na Seção 1, onde fomos forçados ao $c^* = 2$), propomos uma **heurística de realocação dinâmica**.

Durante o laço iterativo, se um cluster perde todas as suas amostras, realocamos seu protótipo para a posição de um ponto aleatório do cluster vizinho mais superpopuloso do momento. Esta alteração garante a exploração máxima das densidades locais. Ao rodarmos o agrupamento com essa trava de segurança (e com otimização prévia do parâmetro de largura da banda via variância), o Índice de Silhueta alterou-se revelando um pico cristalino em $c^* = 4$, conforme evidenciado na Figura 8.




Figura 8: Índice de Silhueta com heurística de resiliência. O pico estrutural claro ocorreu em $c^* = 4$.

Garantindo a estabilidade matemática do algoritmo (já que os clusters nunca esvaziam definitivamente), nós também asseguramos uma descida suave e monotônica do erro. A Figura 9 demonstra o sucesso dessa heurística ao mostrar a convergência perfeita da Função Objetivo J para a partição escolhida de 4 clusters.




Figura 9: Curva de convergência garantida pela heurística de clusters não-vazios ($c^* = 4$).




Figura 10: Matriz de confusão revelando a fragmentação da classe "Good" usando o KCM-K-GH com resiliência ($c^* = 4$).

A matriz de confusão acima evidencia o sucesso desta inovação: a classe *Good* fragmentou-se em subgrupos espacialmente coesos, isolando perfis altíssimamente puros. Com isto, o Índice de Rand Ajustado (**ARI**) saltou de 0.24 para ****0.3282****, provando a superioridade da nossa modificação heurística.




Figura 11: Projecção PCA 2D evidenciando os 4 subgrupos da nossa implementação resiliente.

3.2 Regularização de Covariância de Ledoit-Wolf

No Cenário B da Questão 2, o classificador Bayesiano Gaussiano com Máxima Verossimilhança ruiu (F1 abaixo de 0.4 na curva de aprendizado inicial) devido à má-condição e singularidade de suas matrizes de covariância em cenários desbalanceados.

Para resolver o problema inerente à inversão de matrizes empíricas $p \times p$ quando $N < p$, nós incorporamos o consagrado estimador analítico de encolhimento (*Shrinkage*) proposto por Ledoit e Wolf [Ledoit and Wolf, 2004]. Este estimador realiza uma ponderação convexa ótima entre a matriz de covariância amostral (sem restrições) e a matriz identidade, garantindo um número de condicionamento finito sem necessidade de sintonização via validação cruzada.

Aplicando o *Ledoit-Wolf* ao nosso Bayesiano Gaussiano original, estabilizamos a instabilidade catastrófica vista anteriormente, alcançando convergência firme e elevando exponencialmente o desempenho com poucas amostras. A Figura 12 comprova visualmente esta assertiva: mesmo com menos de 20% dos dados de treinamento particionados para clusters extremamente assimétricos, o modelo Gaussiano Regularizado não sucumbe a matrizes singulares, mantendo-se competitivo no topo junto com os métodos não paramétricos.

Curva de Aprendizagem — F-measure (macro) — Cenário B (10 repetições)




Figura 12: Curva de Aprendizagem (Cenário B - Original). A linha do Bayes Gaussiano (azul) revela enorme estabilidade graças à aplicação do estimador de Ledoit-Wolf.

Referências

- [de Carvalho et al., 2018] de Carvalho, F. d. A. T., Simões, E. C., Santana, L. V. C., and Ferreira, M. R. P. (2018). Gaussian kernel c-means hard clustering algorithms with automated computation of the width hyper-parameters. *Pattern Recognition*, 79:370–386.
- [Kittler et al., 1998] Kittler, J., Hatef, M., Duin, R. P., and Matas, J. (1998). On combining classifiers. *IEEE transactions on pattern analysis and machine intelligence*, 20(3):226–239.
- [Ledoit and Wolf, 2004] Ledoit, O. and Wolf, M. (2004). A well-conditioned estimator for large-dimensional covariance matrices. *Journal of multivariate analysis*, 88(2):365–411.
- [Sigillito et al., 1989] Sigillito, V. G., Wing, S. P., Hutton, L. V., and Baker, K. B. (1989). Classification of radar returns from the ionosphere using neural networks. *Johns Hopkins APL Technical Digest*, 10:262–266.