

Relatório do Projeto: Aprendizagem de Máquina

Agrupamento KCM-K-GH e Classificação Bayesiana (Dataset Ionosphere)

4 de junho de 2026

Resumo

Este relatório detalha as metodologias e implementações desenvolvidas para o projeto da disciplina de Aprendizagem de Máquina. A primeira etapa consistiu no agrupamento das amostras do conjunto de dados *Ionosphere* utilizando o algoritmo *Gaussian kernel c-means hard clustering* (KCM-K-GH), determinando o número ótimo de clusters (c^*) via Índice de Silhueta. A segunda etapa focou na avaliação e comparação rigorosa de cinco classificadores (Bayes Gaussiano, kNN Bayesiano, Parzen, Regressão Logística e Voto Majoritário) por meio de validação cruzada aninhada repetida (30×10 -folds) nos cenários com os rótulos a priori e os rótulos derivados do agrupamento. Realizou-se também a análise estatística utilizando o teste de Friedman e o teste *post-hoc* de Nemenyi.

Sumário

1	Questão 1: Agrupamento KCM-K-GH	2
1.1	Metodologia e Implementação	2
1.2	Escolha do Número Ótimo de Clusters (c^*)	2
1.3	Análise da Matriz de Confusão e ARI	3
2	Questão 2: Comparação de Classificadores	4
2.1	Modelos e Regras de Decisão	4
2.2	Metodologia Experimental e Busca de Hiperparâmetros	4
2.3	Testes Estatísticos de Friedman e Nemenyi	4
2.4	Curvas de Aprendizagem	5
2.5	Tabelas de Resultados (Métricas de Validação)	6
2.6	Diagramas de Diferença Crítica (CD)	7
3	Conclusão	8

1 Questão 1: Agrupamento KCM-K-GH

1.1 Metodologia e Implementação

O conjunto de dados *Ionosphere* foi pré-processado (padronização via *Z-score*) antes de ser alimentado ao algoritmo KCM-K-GH. O algoritmo utilizado baseia-se na minimização da função objetivo que incorpora um kernel gaussiano com hiperparâmetros de largura ajustáveis automaticamente.

O código (`q1_v2.py`) foi implementado com extrema fidelidade às equações de atualização descritas pela literatura base do projeto. Adicionalmente, foi embutido um tratamento de resiliência: se um cluster esvazia durante a fase de atribuição, seu protótipo é reinicializado no espaço dos dados a partir do maior cluster existente, preservando a busca global.

1.2 Escolha do Número Ótimo de Clusters (c^*)

Para determinar a partição ótima e o número de clusters c^* , o algoritmo foi executado para valores de $c \in \{2, 3, 4, 5, 6\}$. Devido à natureza heurística e estocástica (inicialização de Forgy), cada c foi testado com 100 execuções independentes (com sementes aleatórias distintas), capturando a partição que minimizou a função objetivo J para aquele c .

A definição estrita de c^* baseou-se na maximização do **Índice de Silhueta**. Conforme exibido na Figura 1, o maior valor de Silhueta ocorreu para $c = 4$.




Figura 1: Gráfico do Índice de Silhueta versus o número de clusters c . O pico máximo determinou a escolha de $c^* = 4$.

Para esse c^* , a convergência do algoritmo em relação à função objetivo se deu de forma assintótica estável e monotônica (Figura 2). O vetor global de largura s^2 foi analisado. As variáveis com os menores valores de largura s_j determinam os aspectos de maior relevância na aglomeração das amostras, indicando um alto peso discriminatório atribuído pelo kernel a estas *features*.




Figura 2: Curva de convergência da função objetivo J para o valor ótimo $c^* = 4$.

1.3 Análise da Matriz de Confusão e ARI

Utilizando $c^* = 4$, comparamos a partição obtida com as classes *a priori* da base (Good vs. Bad). A Figura 3 ilustra a Matriz de Confusão.




Figura 3: Matriz de confusão (mapa de calor) cruzando as classes *a priori* com os clusters encontrados.

Obteve-se um Índice de Rand Ajustado (ARI) condizente com a complexidade estrutural inerente dos dados originais. Observou-se uma tendência clara da segmentação intrínseca não-linear do conjunto *Ionosphere* que fragmentou as classes binárias primárias em sub-clusters.

2 Questão 2: Comparação de Classificadores

2.1 Modelos e Regras de Decisão

A implementação (q2_v2.py) exigiu alto rigor estatístico e obediência ao critério bayesiano.

- **Classificador Bayesiano Gaussiano:** Modelou a densidade condicional assumindo uma matriz de covariância densa por classe. Para tratar singularidades em subclasses raras, adicionou-se uma regularização à diagonal principal ($\lambda = 10^{-4}$) e uma verificação baseada em número de condicionamento; acionando um limitador flexível (*Ledoit-Wolf shrinkage*) sempre que detectada dependência linear que corromperia o cálculo da matriz inversa.
- **Classificador Bayesiano k -NN:** Diferente do k -NN discriminativo comum, este algoritmo computou o volume da hipersfera contendo os k vizinhos da mesma classe e os aplicou sobre a Fórmula de Bayes (utilizando as fórmulas algébricas fechadas do volume em métricas L1, L2 e L_∞) de forma a obter a densidade de probabilidade legítima $\hat{p}(x|\omega_i)$.
- **Classificador de Parzen:** Modelagem não paramétrica com Função de Kernel Gaussiano simétrica contínua (KDE).
- **Regressão Logística e Comitê Majority Voting:** Aplicados conforme a premissa discriminativa padrão e montagem do *Ensemble* agregador.

2.2 Metodologia Experimental e Busca de Hiperparâmetros

O ambiente avaliativo baseou-se em Validação Cruzada Aninhada (Nested CV) rigorosa. No laço externo, usou-se Estratificação Repetida (10 Folds $\times$ 30 Repetições = 300 amostras estatísticas). No laço interno, utilizou-se *GridSearch* com 5-folds para otimização ótima de:

- **kNN Bayesiano:** $k \in \{1, 3, 5, 7, 9, 11\}$ e métricas de distanciamento L1, L2 e L_∞ .
- **Parzen:** Busca logarítmica para h (largura da banda).
- **Regressão Logística:** Parâmetro C de regularização.

Os experimentos foram aplicados sobre dois cenários de aprendizado:

- **Cenário A:** Classes *a priori* da base Ionosphere (binário).
- **Cenário B:** Rótulos atribuídos pela partição $c^* = 4$ (da Questão 1).

2.3 Testes Estatísticos de Friedman e Nemenyi

Todas as métricas (Erro, Precisão, *Recall* e *F-Measure*) foram gravadas nos 300 cenários de dobra externa. Foi aplicado o Teste Não-paramétrico de **Friedman** ($\alpha = 0.05$) com a correção sobre os blocos (Cálculo do F_F e probabilidade de F-Distribuição) visando descartar a hipótese nula de desempenho idêntico entre os 5 classificadores. Caso rejeitado o H_0 , seguiu-se com o Teste de **Nemenyi**, utilizando as tabelas padronizadas q_α e determinando a Distância Crítica (CD) baseada nos *Mean Ranks* com o fito de isolar qual modelo diferiu significativamente dos pares adjacentes.

2.4 Curvas de Aprendizagem

As Curvas de Aprendizagem (do percentual de treino 5% até 95%) foram concebidas com um amortecedor de ruído: 10 repetições fixas para cada proporção de treino, resultando na convergência suavizada (F-Measure Macro) reportada, o que expôs precisamente o teto bias-variance dos algoritmos em baixa taxa de dados.

**Curva de Aprendizagem — F-measure (macro) — Cenário A
(10 repetições)**




Figura 4: Curva de Aprendizagem — Cenário A (Rótulos Originais). Amortecida sob 10 partições estocásticas em cada ponto amostral percentual.

Curva de Aprendizagem — F-measure (macro) — Cenário B (10 repetições)




Figura 5: Curva de Aprendizagem — Cenário B (Rótulos do Agrupamento KCM-K-GH). Estabilidade do modelo Bayes Gaussiano assegurada através do método Shrinkage para tratar dimensões escassas com baixas porcentagens de partição.

2.5 Tabelas de Resultados (Métricas de Validação)

As Tabelas 1 e 2 consolidam o desempenho médio de todas as métricas observadas (Erro, Precisão, Recall e F-measure), além de seus respectivos Intervalos de Confiança (IC 95%), para os cinco classificadores após o término da etapa de Validação Cruzada Aninhada.

Tabela 1: Estimativas Pontuais e IC (95%) de todas as métricas — Cenário A (Rótulos a Priori).

Classificador	Erro	Precisão (macro)	Recall (macro)	F-measure (macro)
Bayes Gaussiano	0.112 [0.106, 0.118]	0.881 [0.875, 0.888]	0.891 [0.886, 0.897]	0.881 [0.875, 0.888]
k -NN Bayesiano	0.092 [0.087, 0.097]	0.928 [0.923, 0.933]	0.878 [0.871, 0.885]	0.893 [0.887, 0.899]
Parzen	0.127 [0.121, 0.133]	0.902 [0.897, 0.907]	0.831 [0.823, 0.838]	0.848 [0.840, 0.855]
Regressão Log.	0.121 [0.116, 0.127]	0.892 [0.886, 0.898]	0.848 [0.840, 0.855]	0.860 [0.853, 0.867]
Voto Majoritário	0.064 [0.060, 0.069]	0.943 [0.938, 0.947]	0.920 [0.914, 0.926]	0.928 [0.922, 0.933]

Tabela 2: Estimativas Pontuais e IC (95%) de todas as métricas — Cenário B (Clusters).

Classificador	Erro	Precisão (macro)	Recall (macro)	F-measure (macro)
Bayes Gaussiano	0.244 [0.236, 0.252]	0.796 [0.781, 0.811]	0.654 [0.642, 0.666]	0.683 [0.670, 0.696]
k -NN Bayesiano	0.071 [0.067, 0.076]	0.943 [0.938, 0.948]	0.920 [0.913, 0.926]	0.923 [0.917, 0.929]
Parzen	0.068 [0.063, 0.073]	0.953 [0.947, 0.958]	0.916 [0.909, 0.924]	0.926 [0.919, 0.932]
Regressão Log.	0.040 [0.037, 0.044]	0.964 [0.960, 0.968]	0.960 [0.956, 0.965]	0.959 [0.954, 0.963]
Voto Majoritário	0.045 [0.041, 0.049]	0.966 [0.962, 0.971]	0.935 [0.928, 0.942]	0.944 [0.938, 0.950]

2.6 Diagramas de Diferença Crítica (CD)

De acordo com o Teste *post-hoc* de Nemenyi, as diferenças significativas entre o ranqueamento dos classificadores para a métrica primária (*F-measure*) foram sumarizadas nos Diagramas de Diferença Crítica (CD). Os modelos conectados pela mesma barra espessa não apresentam diferença estatística significativa sob $\alpha = 0.05$.




Figura 6: Diagrama CD para o Cenário A. A Distância Crítica (CD) para 5 classificadores e 300 folds é de 0.3522.

Diagrama de Diferença Crítica (CD) - Cenário B (F1)
CD = 0.3522




Figura 7: Diagrama CD para o Cenário B. Evidencia a formação de grupos equivalentes de performance.

3 Conclusão

Os algoritmos desempenharam os papéis teóricos fundamentais projetados pela disciplina de Aprendizagem de Máquina. A implementação cuidadosa no classificador baseado em k-vizinhos (sendo legítimo algoritmo *Bayesiano*) e o uso de estimadores flexíveis como o Ledoit-Wolf proveram robustez singular. A avaliação estatística aninhada com Friedman atestou com rigor incontestável as capacidades de generalização e discriminação dos métodos estudados sobre as densidades estocásticas deste escopo.

Referências

- [1] Sigillito, V. G., Wing, S. P., Hutton, L. V., & Baker, K. B. (1989). Classification of radar returns from the ionosphere using neural networks. *Johns Hopkins APL Technical Digest*, 10, 262-266.
- [2] Referência base do KCM-K-GH. (*Substitua aqui pela referência exata do artigo fornecido pelo Prof. Francisco sobre o algoritmo de agrupamento KCM-K-GH*).
- [3] Ledoit, O., & Wolf, M. (2004). A well-conditioned estimator for large-dimensional covariance matrices. *Journal of multivariate analysis*, 88(2), 365-411.
- [4] Demšar, J. (2006). Statistical comparisons of classifiers over multiple data sets. *Journal of Machine learning research*, 7, 1-30.